

1. Introduction

흐름: **Visual Intelligence** → **Computer Vision의 역사** → **Neural Network의 역사**
→ **ImageNet·AlexNet** → **현대 Computer Vision** → **CS231N 전체 구성**

Computer Vision: 이미지·영상에서 정보를 추출해 **대상, 위치, 관계, 행동, 3차원 구조**를 인식하는 분야.

- Vision: physics of materials
- Language: nature 존재 X. generated. 1D. sequential.

0. Visual Intelligence

Evolution's Big Bang — Cambrian Explosion

- 약 5억 3천만 년 전 생물 종이 급격히 다양해짐.
- **시각의 발달** = 변화의 주요 원인 중 하나.
- vision → intelligent behavior를 가능하게 하는 입력.

Camera Obscura

- 작은 구멍을 통과한 빛이 반대편 벽에 뒤집힌 상을 만듦.
- 카메라의 기본 원리.
- 영상은 현실 자체가 아니라 **빛이 투영된 2차원 결과**.

⇒ Computer Vision은 2차원 픽셀만 보고 원래의 3차원 세계를 추론해야 함.

1. Biological Vision → Early Computer Vision

Hubel & Wiesel, 1959

고양이에게 여러 방향의 선을 보여주고 시각 피질의 neuron 반응을 측정.

- **Receptive field**: 하나의 neuron이 반응하는 시야의 특정 영역.
- **Simple cell**: 특정 위치·방향의 선에 반응.
- **Complex cell**: 선의 방향과 움직임에 반응하며 위치 변화에도 어느 정도 안정적.

⇒ 작은 영역의 단순한 특징부터 검출하고, 이를 조합해 복잡한 대상을 인식하는 **hierarchical processing**.

CNN의 local receptive field와 계층적 feature extraction으로 이어지는 아이디어.

Larry Roberts, 1963

목표: 2D 이미지에서 3D 물체 구조 복원.

대상: 단순한 다면체 중심.

과정:

1. 원본 영상
2. 밝기 변화 계산
3. edge와 feature point 검출
4. 선 연결
5. 3D solid 추정

⇒ 초기 Computer Vision은 현실 영상 전체보다 **기하학적 구조 복원**에 집중.

David Marr, 1970s — Stages of Visual Representation

Input Image → Primal Sketch → 2.5-D Sketch → 3-D Model Representation

- **Input Image**: 픽셀, 밝기 정보.
- **Primal Sketch**: edge, blob, bar, curve, boundary 검출.
- **2.5-D Sketch**: 관찰자 기준의 depth, surface orientation 표현.
- **3-D Model**: 물체의 3차원 구조 표현.

2. Hand-Crafted Recognition의 발전

Recognition via Parts, 1970s

물체를 여러 부분으로 분해한 뒤, 부분 사이의 배치로 인식.

- **Generalized Cylinders**: 물체를 원기둥 형태의 부품으로 표현.
- **Pictorial Structures**: 물체의 부분과 연결 관계를 그래프로 표현.

장점: 물체의 구조를 명시적으로 표현.

한계: 현실의 다양한 물체 형태를 미리 정한 부품으로 표현하기 어려움.

Recognition via Edge Detection, 1980s

대표: **Canny Edge Detector**

- pixel 밝기가 급격히 변하는 위치 검출.
- 물체의 윤곽과 내부 경계를 찾음.

문제:

- 그림자도 edge를 생성.
 - 배경 무늬에도 많은 edge가 존재.
 - edge만으로 어느 물체인지 판단하기 어려움.
-

3. Perceiving Real-World Scenes — 사람의 장면 인식

Biederman, 1972 — Perceiving Real-World Scenes

같은 장면을 두 방식으로 제시:

- **정상 장면**: 건물, 나무, 자전거, 사람이 실제 공간 관계에 맞게 배치됨.
- **뒤섞인 장면**: 동일한 부분들을 잘라 위치를 바꾸고 재배치함.

결과: object recognition은 물체 자체의 모양과 scene context를 함께 사용.

- 정상 장면에서 물체를 더 잘 인식.
 - 장면의 부분만 존재한다고 인식이 유지되지 않음.
 - 물체와 주변 환경의 **공간적 관계·맥락**이 object recognition에 영향을 줌.
-

Rapid Serial Visual Perception, Potter et al., 1970s

RSVP: 여러 이미지를 같은 위치에 매우 빠르게 연속 제시하는 실험.

사람은 빠른 시간에 사물 인식/분류 + 특징 인식 가능.

4. Visual Recognition — CV 발전

Recognition via Grouping, 1990s

대표: **Normalized Cuts, 1997**

전경 및 배경 분리(grouping)

Recognition via Matching, 2000s

대표: SIFT, 1999

1. 이미지에서 특징점 검출
2. 특징점 주변을 descriptor로 표현
3. 다른 이미지의 descriptor와 비교
4. 대응점이 많은 물체를 같은 대상으로 판단

예: 두 이미지의 위치는 달라도 특징점 descriptor를 대응시킬 수 있음.

정면의 STOP 표지판 특징
↔ 기울어진 STOP 표지판 특징

Viola-Jones Face Detector, 2001

- 얼굴 검출에 machine learning을 성공적으로 적용한 초기 사례.
- 영상 전체에서 얼굴이 있을 만한 영역을 빠르게 탐색.
- 실시간 얼굴 검출 시스템에 활용.

당시 일반적인 pipeline:

Image → 사람이 feature 설계 → feature 추출 → classifier 학습 → prediction

Deep Learning과의 차이:

고전적 방법: 사람이 feature를 설계
Deep Learning: feature와 classifier를 함께 학습

5. Neural Network의 역사

Perceptron, 1957-1958

입력의 weighted sum으로 두 class를 나누는 linear classifier.

- 하나의 직선 또는 평면으로 구분 가능한 문제에 사용.
- 파라미터: weight, bias.

Minsky & Papert, 1969 — XOR

XOR의 0과 1은 하나의 직선으로 분리할 수 없음.

⇒ single-layer Perceptron은 XOR을 학습할 수 없음.

여러 layer와 nonlinear activation을 사용하면 해결 가능하지만, 당시에는 이를 효율적으로 학습시킬 방법이 부족했음.

Neocognitron, 1980

Hubel & Wiesel의 simple cell·complex cell 구조에서 영감을 받음.

- 현대 CNN과 유사한 계층 구조.
 - practical training algorithm이 없었음.
 - 사람이 구조와 파라미터를 설계해야 했음.
-

Backpropagation, 1986

출력 오차를 뒤에서부터 전달하며 각 weight의 gradient를 계산.

```
Forward
입력 → 예측 → loss 계산

Backward
loss → 각 layer의 gradient → weight 수정
```

Chain rule ⇒ multi-layer neural network의 파라미터를 데이터로 학습할 수 있게 됨.

LeNet, 1998

- CNN 사용
 - Neocognitron과 유사한 구조에 backpropagation을 적용.
-

5. 2000s Deep Learning

- Architecture 존재 + Backpropagation 존재
 - Large-scale Data 부족 + Computation 부족
-

6. ImageNet과 AlexNet

ImageNet, 2009

ImageNet Large Scale Visual Recognition Challenge:

- 대규모 supervised training data 제공.
 - 여러 모델을 동일한 조건에서 비교.
 - 복잡한 model을 학습할 충분한 사례 제공.
-

AlexNet, 2012

- backpropagation으로 전체 parameter 학습.
 - data 중요성 인식
-

Part II — CS231N Course Overview

| 흐름: 분류 기초 → 다양한 perception task → model architecture → 생성·3D·행동
→ Human-Centered AI

1. Deep Learning Basics

- **Optimization**: training loss를 낮추는 parameter 탐색.
- **Regularization**: training data에 과도하게 맞는 것을 방지해 generalization 개선.

2. Perceiving and Understanding the Visual World

image classification

- classification: 주어진 label로 분류
- semantic segmentation: 객체 구분 X. pixel 단위 구분
- object detection: bounding box 처리
- Instance Segmentation: semantic segmentation + object detection

기타

- video classification
- multimodal video understanding
- visualization & understanding

Models Beyond MLP

CNN

- 이미지의 local structure 사용.
- 같은 filter를 여러 위치에 공유.
- edge → texture → part → object 순서로 feature 학습.

RNN

- 이전 hidden state를 다음 시점으로 전달.
- 순서가 있는 데이터 처리.
- 영상·문장과 같은 sequential data에 사용.

Attention / Transformer

- 입력의 여러 위치 사이 관계 계산.
- 멀리 떨어진 영역 사이의 상호작용 표현.
- 이미지와 텍스트를 함께 처리하기 좋음.

Parallelism

- Data parallelism: data가 너무 많을 때.
- Model parallelism: model이 하나의 GPU에 들어가지 않을 때.

3. Generative and Interactive Visual Intelligence

Self-Supervised Learning

label 없이 데이터 자체에서 학습 신호 구성.

예: 같은 강아지 이미지의 서로 다른 변형.

```
dog image 1 → embedding z1
dog image 2 → embedding z2
D(z1, z2)를 작게 학습
```

같은 대상의 representation은 가깝게 만들고, 다른 대상은 멀게 만듦.

Generative Modeling

- 스타일 변환

- 이미지 생성
- Diffusion model

Vision Language Model

멀티모달 모델

3D vision

Embodied Intelligence